
title: 博客外链资源库自动化系统 · 需求文档 date: 2026-07-03 version: v0.2 status: 待开发 owner: Ma Boyang changelog: v0.2 (2026-07-03): 修复6处逻辑问题；根据 cloudhu2000 插件真实运行数据 (blog_run_stats_2026-06-22_to_2026-06-28.csv) 补充外部链接数过滤、页面 AS字段、阈值校准 v0.3 (2026-07-03): 删除 Module 4 (测试提交)；本系统仅负责建库，外链投放由 autoComment 插件执行；增加 autoComment 反馈回写机制

博客外链资源库自动化系统 · 需求文档

背景与目标


背景： 博客评论外链是一种低成本、可规模化的SEO外链获取方式。核心是找到“有评论区、允许填写网址、且链接为dofollow”的博客，在上面发布与内容相关的评论并附上自己的网站链接。

目前市面上存在人工整理的付费博客列表（约250条，¥19.9），但存在以下问题：

- 列表静态，不持续更新
- 无法按自己的产品方向筛选相关博客
- 对第三方产生依赖

目标： 构建一套自动化系统，能够持续发现、验证、管理可用于博客评论外链的目标站点，产出标准化的博客资源库，供后续评论工具（如 `backlink-helper` 插件）直接调用。

系统总览



Module 1：SERP抓取

功能说明

根据输入的关键词，自动构造Google搜索指令，批量抓取有评论区的博客页面URL。

输入

- 关键词列表（支持单个或批量）
- 语言/地区参数（如：英语/全球，日语/日本）
- 每个关键词的最大抓取结果数（默认100条）

搜索指令模板

系统自动将输入关键词拼入以下模板：

```
"leave a reply" "website" {keyword}
"leave a comment" "your website" {keyword}
"add a comment" "name" "email" "website" {keyword}
inurl:/blog/ "powered by wordpress" "leave a reply" {keyword}
"post a comment" "website url" {keyword}
```

每个关键词生成约5条搜索指令，每条指令抓取前20个结果，单关键词最多产出约100个候选URL。

抓取方式

- 调用 **SerpAPI**（推荐）或 **ScraperAPI** 获取Google搜索结果
- 不直接爬取Google页面（会触发封锁）
- 抓取字段：URL、页面标题、摘要文本

去重处理

- 同一域名下不同路径的URL：保留，均加入候选列表（同一博客可能有多篇文章可发评论）
- 完全相同的URL：去重，只保留一条

输出

候选URL列表， 字段：

```
url | page_title | domain | keyword_source | crawl_time
```

Module 2：页面验证

功能说明

对Module 1输出的候选URL逐一访问，判断该页面是否包含有效的博客评论表单。

判断条件（同时满足以下三点才算有效）

条件A：存在评论表单 页面HTML中存在 `<form>` 标签，且该表单含有以下字段（通过name/id/placeholder识别）：

- 姓名字段：`name`、`author`、`commentAuthor` 等
- 邮箱字段：`email`、`mail` 等
- 网址字段：`url`、`website`、`link`、`homepage` 等
- 评论内容字段：`comment`、`message`、`content` 等

条件B：网址字段可填写 网址字段不为 `readonly`、`disabled`、`hidden`，即用户可以实际输入URL。

条件C：链接dofollow检测 抓取该页面上已有的评论区链接，检测其 `rel` 属性：

- `rel` 属性含 `nofollow`、`ugc`、`sponsored` 中任意一个 → 标记为 **nofollow**
（Google 2019年更新后，`ugc/sponsored` 与 `nofollow` 同等对待，WordPress 评论区默认输出 `rel="ugc"`，必须纳入检测）
- `rel` 属性不含上述三个值 → 标记为 **dofollow**
- 无 `rel` 属性 → 标记为 **dofollow**（默认）
- 评论区无已有链接 → 标记为 **unknown**（无法判断）

附加检测项（非必须但记录）

检测项	说明
CMS类型	检测是否为WordPress（通过wp-content路径、generator meta tag识别）
评论数量	页面上已有评论数量（数量多说明评论区活跃、审核宽松）
页面语言	通过 <code><html lang></code> 或内容识别
是否需要登录才能评论	检测评论区是否有登录提示
外部链接数量	页面上全部外部链接总数（对应 cloudhu2000 插件的「外部链接数量」字段）。链接过多意味着单条链接权重被稀释，真实数据中出现过单页 31,841 条外部链接的极端情况。过滤规则： ≤ 500 正常保留；501–2000 低优先级标记； > 2000 直接丢弃
页面AS	页面级 Authority Score（对应 cloudhu2000 插件的「页面AS」字段，来源为 SEMrush 或 DataForSEO）。与 Module 3 的域名 DR 是不同维度，均需记录

技术实现

- 使用 **requests + BeautifulSoup** 处理静态页面
- 如果页面检测到JavaScript渲染（评论区由JS加载），使用 **Playwright** 无头浏览器抓取
- 超时设置：10秒，超时则标记为 `timeout`，跳过
- 并发数：建议5-10个并发，避免触发目标站点反爬

输出

在候选URL列表基础上增加字段：

```
has_comment_form | has_website_field | dofollow_status | cms_type |
comment_count | page_language | needs_login | external_link_count |
page_as | page_content_snippet | validation_status
```

- `page_content_snippet`：页面正文摘要（约500字），供 Module 4 AI 自动标注 `topic_category` 时调用

- `validation_status` 取值：`valid` / `no_form` / `no_website_field` / `login_required` / `too_many_links` (外链>2000) / `timeout` / `error`
- `validation_status` 非 `valid` 的记录：保留在候选表中供审查，不进入后续模块

Module 3：DR / AS 过滤

指标说明（重要）

本系统同时追踪两个权重指标，来源和用途不同：

指标	全称	维度	来源	对应插件字段
Domain DR	Ahrefs Domain Rating	域名级	DataForSEO / Ahrefs	—
页面 AS	Authority Score	页面级	DataForSEO / SEMrush	cloudhu2000 插件「页面AS」

DR 反映域名整体权重；页面 AS 反映该具体页面的权威度，两者互补。cloudhu2000 插件导出的「页面AS」字段已在 Module 2 记录，本模块补充查询域名 DR。

DR 查询方式

- 优先使用 **DataForSEO API**（支持批量查询，成本低，可同时返回 DR 和 AS）
- 备选：**Ahrefs API**（成本较高，但数据权威）
- 每次查询以域名为单位（非页面URL），同一域名下多个URL只查一次

过滤规则

依据 cloudhu2000 真实运行数据（blog_run_stats_2026-06-22_to_2026-06-28.csv）校准阈值：插件实际使用的页面AS分布为 5–74，其中「高AS」专项名单下限为 51。

DR范围	处理方式	说明
DR ≥ 30	高优先级, 进入验证队列	对应插件高AS名单质量区间
DR 10–29	中优先级, 进入验证队列	插件日常运行主体区间
DR 1–9	低优先级, 保留入库, 标记低优	插件中有AS 5–9的站点实际被使用
DR = 0 或无数据	丢弃	无权重信号, 无保留价值

DR阈值应可在配置文件中调整。

输出

在验证列表基础上增加字段：

domain_dr | dr_priority | dr_checked_at

Module 4：数据库管理

功能说明

统一存储和管理所有经过验证的博客资源，支持搜索、筛选、导出，并定期重新验证资源的有效性。

数据库字段（每条记录）

字段	说明
id	自增主键
url	博客页面完整URL
domain	根域名
page_title	页面标题
page_language	页面语言（en/zh/ja/ar等）
cms_type	CMS类型（wordpress/blogger/other）
domain_dr	域名DR值（来源：DataForSEO）
page_as	页面 Authority Score（来源：DataForSEO，对应 cloudhu2000 「页面 AS」 字段）
external_link_count	页面外部链接总数（来源：Module 2 抓取，链接稀释信号）
dofollow_status	dofollow / nofollow / unknown
comment_count	已有评论数量
approval_status	<code>unsubmitted</code> （待投放） / <code>approved</code> （评论已通过） / <code>rejected</code> （被拒绝） / <code>pending</code> （等待审核） / <code>disappeared</code> （曾通过后被删）
keyword_tags	来源关键词标签（逗号分隔）
topic_category	内容分类标签（见下方分类定义）
created_at	首次入库时间
last_verified_at	最近一次验证时间
is_active	是否当前可用（布尔值）
notes	备注

TOPIC_CATEGORY 分类定义

初始分类列表（v0.1，后续可扩展）：

分类值	含义
seo_marketing	SEO、数字营销、增长黑客
tech_tools	技术工具、在线工具、SaaS
lifestyle	生活方式、旅游、美食、健康
business	商业、创业、电商
education	教育、学习、语言
entertainment	娱乐、游戏、文化
other	未分类或混合型博客

标注方式：v0.1 阶段使用 AI 自动标注——将页面标题 + `page_content_snippet` 传入 AI，按上表分类后写入字段；无法判断时写入 `other`。人工可随时覆盖。

搜索与筛选

支持按以下维度筛选：

- DR范围
- dofollow状态
- 页面语言
- topic_category
- approval_status
- is_active

导出格式

支持导出为 **CSV**，字段格式兼容 backlink-helper 插件的导入格式（至少包含：url、domain、dr、dofollow_status）。

定期重新验证

- 每30天对 `is_active = true` 的记录重新执行 Module 2（页面验证）
- 如果页面评论表单消失或已转为 nofollow，将 `is_active` 更新为 false
- DR/AS 数据（DataForSEO）每60天重新拉取一次

AUTOCOMMENT 集成与反馈回写

插件开源地址：https://github.com/cloud-hu2000/autoCommentSMARTPANTS_PRESERVED_633 建议同事阅读其导入格式和输出结构，确保本系统 CSV 与插件兼容。

分工说明：

- 本系统（Module 1–4）：发现、验证、管理可用博客站点，产出标准化资源库（CSV）
- autoComment 插件：读取资源库 CSV，自动向这些站点批量投放外链评论，产出运行结果 CSV（格式参考 `blog_run_stats_2026-06-22_to_2026-06-28.csv`）

反馈回写（Feedback Import）：

autoComment 每次运行后会输出结果 CSV，本系统提供一个导入命令，读取该文件并将投放结果写回数据库：

<u>autoComment 输出字段</u>	<u>对应数据库字段</u>	<u>更新逻辑</u>
<u>原URL</u>	<u>url</u>	<u>匹配记录</u>
<u>投放结果（approved/rejected/pending）</u>	<u>approval_status</u>	<u>直接更新</u>
<u>运行时间</u>	<u>last_verified_at</u>	<u>更新为本次投放时间</u>

`disappeared` 状态：当某条记录 `approval_status = approved`，但 autoComment 下次投放时该站点回访失败或评论不再存在，则将状态更新为 `disappeared`，`is_active` 置为 false。

系统配置文件

系统应支持通过配置文件（YAML或JSON）调整以下参数，无需改代码：

```

serp:
  api_provider: serpapi          # serpapi / scraperapi
  api_key: YOUR_KEY
  results_per_query: 20
  max_queries_per_keyword: 5

validation:
  timeout_seconds: 10
  concurrency: 8
  use_playwright: true          # 是否对JS渲染页面启用无头浏览器

dr_filter:
  api_provider: dataforseo       # 已确认使用 DataForSEO（同时返回 DR 和 AS）
  api_key: YOUR_KEY
  dr_high_threshold: 30          # DR≥30 高优先级
  dr_medium_threshold: 10       # DR 10-29 中优先级
  dr_low_min: 1                 # DR 1-9 低优先级（保留入库，不丢弃）
                                # DR=0 或无数据 → 丢弃（无需单独配置）

database:
  type: sqlite                  # sqlite / postgresql
  path: ./backlink_db.sqlite
  reverify_days: 30
  dr_refresh_days: 60
  
```

技术栈建议

组件	建议技术
语言	Python 3.10+
HTTP请求	requests / httpx
页面解析	BeautifulSoup4
JS渲染页面	Playwright
数据库	SQLite（轻量）或 PostgreSQL（生产）
任务调度	APScheduler（定期重验证）
SERP接口	SerpAPI
DR/AS 查询接口	DataForSEO（批量查询 domain_dr + page_as, 单次调用两个指标）
AI分类标注	硅基流动 / OpenRouter（仅用于 topic_category 自动标注）

各模块估算成本

成本项	单价	预计用量（首次建库500条）	估算费用
SerpAPI	\$50/5000次查询	约500次	~\$5
DataForSEO DR/AS查询	\$0.002/条域名	约500个域名	~\$1
AI topic_category 标注	~¥0.01/条（Qwen72B）	约500条	~¥5
合计首次建库	—	—	约\$6 + ¥5
后续每月维护（重验证）	—	500条×每月	约\$1-2/月

交付物清单

- ☐ [Python项目代码（含requirements.txt）](#)
- ☐ [配置文件模板（config.yaml.example）](#)
- ☐ [数据库初始化脚本](#)
- ☐ [命令行使用说明（README.md）](#)
- ☐ [导出CSV格式说明（兼容backlink-helper插件）](#)
- ☐ [定时任务配置示例](#)

开发优先级

优先级	模块	原因
P0	Module 1（SERP抓取）	是整个流程的数据源头
P0	Module 2（页面验证）	核心筛选逻辑
P1	Module 3（DR/AS过滤）	质量保障
P1	Module 4（数据库+导出CSV）	产出可用资源库，打通 autoComment 插件
P2	autoComment 反馈回写	关闭数据闭环，可后期加
P2	定期重验证调度	维护成本优化，可后期加

[文件：inbox/00-inbox/2026-07-03-博客外链资源库自动化系统-需求文档.md 版本：v0.3 / 2026-07-03](#)